

Ingénieur DevOps & data au service de la
modernisation des Services Statistiques Publics

EXPERIENCE

Ministère de la sécurité intérieur

Data Scientist et référent technique informatique

Paris, France
2024 - aujourd’hui

Aide à la Data Engineering, traitement, fiabilisation et automatisation de données. Exploitation de données sensibles à grande échelle en environnement sécurisé (RGPD). SQL avancé et optimisé (PostgreSQL, DuckDB), Python (pandas, numpy, pyarrow, SQLAlchemy). Construction et amélioration de flux de données (ETL) avec Apache Airflow. Gouvernance et contrôle qualité des données. Production d’indicateurs d’aide à la décision publique.

Responsable des publications sur la délinquance économique et financière

- **Refonte des processus ETL** 2024-Présent

Langages : Python, SQL, R

Outils/Packages : Apache Airflow, Pandas, NumPy, DuckDB, PostgreSQL

Difficultés : Systèmes hérités avec 20+ ans de dette technique ; Résistance au changement de la part des parties prenantes non techniques ; Problèmes de qualité des données dans les systèmes sources ; Nécessité de maintenir la production pendant la migration

Refonte des processus ETL pour 20+ agents, permettant de réduire de plus de 80% le délai entre les acquisitions de données et la mise en production. Mise en place de traitement incrémentiel, de cadres de validation des données et d’alertes automatisées. Formation des membres de l’équipe aux nouveaux processus et outils.
- **Mise en place d’une culture du changement** 2024-Présent

Langages : Python, Markdown, Bash

Outils/Packages : Git, GitHub, Docker, Jupyter, VS Code

Difficultés : Public hétérogène avec des compétences techniques variées (de Excel uniquement à Python avancé) ; résistance à l’adoption de nouveaux outils ; besoin de démontrer une valeur immédiate

Mise en place d’une culture du changement avec des outils et méthodes de travail plus modernes. Création de documentation, de modèles et de kits de démarrage. Organisation de sessions de formation et d’ateliers. Développement d’outils internes pour réduire la barrière à l’entrée pour les utilisateurs non techniques.
- **Outils open-source de publication** 2024-Présent

Langages : Python, TypeScript, JavaScript

Outils/Packages : React, FastAPI, Pandas, GitHub Actions, Docker

Difficultés : Équilibre entre flexibilité et standardisation ; garantie de la reproductibilité ; gestion des dépendances ; considérations de sécurité pour les outils destinés au grand public

Développement d’outils internes puis open source pour la publication industrialisée d’articles et de contenus ouverts au grand public, réduisant la dette technique et la dépendance. Mise en place de pipelines CI/CD, de tests automatisés et de génération de documentation.
- **Modèles LLM pour le clustering de texte** 2024-Présent

Langages : Python

Outils/Packages : Transformers, scikit-learn, Sentence-BERT, HuggingFace

Difficultés : Contraintes de confidentialité (NDA) ; traitement de texte français avec jargon technique ; sélection et fine-tuning de modèles ; optimisation des performances

Co-design, développement et déploiement de modèles LLM pour clusteriser les réponses d’enquête à champs libres. Mise en œuvre de l’ingénierie de prompts, évaluation de plusieurs architectures de modèles et déploiement de la solution en environnement de production.
- **Études sur la délinquance économique et financière** 2024-Présent

Langages : Python, R, SQL

Outils/Packages : Pandas, ggplot2, dplyr, PostgreSQL, DuckDB

Difficultés : Données provenant de multiples sources (Police Nationale, Gendarmerie) avec différents formats ; traitement de données sensibles ; besoin d’analyses reproductibles

Rédaction d’études sur la délinquance économique et financière en utilisant les données de la Police Nationale et de la Gendarmerie. Développement de pipelines d’analyse standardisés et de modèles de visualisation.

— **INSEE**

Ingénieur DevOps

Nantes, France
2021 – 2024

Support et exploitation de systèmes d’information critiques. POC avec technologies avancées de Python (pandas, numpy, Dask, scikit-learn, XGBoost, TensorFlow/PyTorch, MLflow, Polars, pyarrow, Modin, Ray, FastAPI). Support et maintien de systèmes d’information critiques : stack complète en environnement conteneurisé (Docker, Kubernetes, Helm) avec couches basses (Linux Ubuntu/Debian, réseaux TCP/IP, stockage S3) et hautes (PostgreSQL, Redis, microservices). Analyse et résolution d’incidents applicatifs internes et open source. Amélioration continue des flux et processus SI avec observabilité (Prometheus, Grafana, ELK, OpenTelemetry).

DevOps et support de la plateforme de datascience de l’INSEE

- **Développement de la plateforme Onyxia** 2021-2024
Langages : Go, Python, TypeScript, YAML
Outils/Packages : Kubernetes, Helm, Docker, GitLab CI/CD, GitHub Actions, ArgoCD, Vault, Prometheus, Grafana
Difficultés : Architecture multi-locataires complexe ; exigences de sécurité pour les données gouvernementales ; intégration avec les systèmes hérités ; besoins de scalabilité
Co-développement et installation d'une *Plateforme As A Service (Onyxia)*. Conception d'architecture microservices, mise en œuvre de l'authentification/autorisation, et déploiement de la stack de monitoring.
- **Implémentation d'une stack technique moderne** 2021-2024
Langages : Bash, Python, YAML
Outils/Packages : Docker, Helm, Pipelines GitLab, GitHub Actions, Grafana, Prometheus, Vault, Terraform, Ubuntu/Debian, S3
Difficultés : Résistance au changement de la part de l'équipe existante ; nécessité de maintenir les anciens systèmes pendant la transition ; besoins de formation pour 500+ utilisateurs
Développement et remplacement de la stack technique complète et neuve. Création de guides de migration, automatisation des processus de déploiement et réduction du temps de déploiement de plusieurs semaines à quelques heures (accélération par 10).
- **Support aux Data Scientists** 2021-2024
Langages : Python, R, Bash
Outils/Packages : JupyterHub, RStudio Server, PyCharm, VS Code, Kubernetes
Difficultés : Large éventail de niveaux de compétence des utilisateurs (débutants à avancés) ; cas d'usage variés (notebooks, tableaux de bord, IDE) ; contraintes de ressources
Support de proximité aux *Data Scientists* débutants jusqu'aux avancés pour l'intégration de leurs services (notebooks, applications internes de dataviz, IDE data : Rstudio & Pycharm). Développement de modèles, de documentation et de bonnes pratiques.
- **INSEE** Nantes, France
Ingénieur data plateforme 2020 – 2021

Sys-admin de la plateforme de datascience interne
- **Déploiement de composants de plateforme** 2020-2021
Langages : PowerShell, Batch, Python
Outils/Packages : Windows Server, Active Directory, IIS, SQL Server
Difficultés : Infrastructure héritée avec des ressources limitées ; contraintes de sécurité ; besoin de haute disponibilité ; gestion complexe des utilisateurs
Mise en place de briques permettant à 500+ datascientists de l'INSEE de gagner jusqu'à 80% de leur temps pour déployer des outils et études internes. Automatisation des scripts de déploiement et création de portails en libre-service.
- **Système de monitoring des ressources** 2020-2021
Langages : Python, PowerShell
Outils/Packages : Prometheus, Grafana, Compteurs de performance Windows
Difficultés : Visibilité limitée sur l'utilisation des ressources ; ressources physiques partagées ; priorités concurrentes ; besoin de données historiques
Mise en place de monitoring et de supervision des processus pour cadencer les ressources physiques partagées (windows server). Optimisation de 20% des ressources utilisées. Mise en place d'outils d'alerte et de planification de la capacité.
- **Initiative de traduction de code** 2020-2021
Langages : Python, R
Outils/Packages : Pandas, tidyverse, reticulate
Difficultés : Code propriétaire de 20 ans ; documentation limitée ; résistance des utilisateurs à l'aise avec l'ancien système ; exigences de compatibilité
Mise en place de projets de traduction de code pour sortir d'une licence propriétaire de data-analyse implantée depuis 20 ans. Développement d'outils de migration et formation aux alternatives open-source.
- **Central Statistics Office** Dublin, Irelande
Stage de fin d'études 2020
Assistant Statisticien
- **Rapport officiel des statistiques annuelles** 2020
Langages : R, LaTeX
Outils/Packages : knitr, ggplot2, dplyr, R Markdown
Difficultés : Délai serré ; besoin de mise en forme officielle du gouvernement ; collaboration avec plusieurs parties prenantes ; exigences de validation des données
Co-édition du rapport officiel sur les statistiques annuelles de l'Irlande. Développement de pipeline de génération de rapports automatisés et création de modèles réutilisables pour les rapports futurs.
- **Traitement des données météorologiques historiques** 2020
Langages : R, Python
Outils/Packages : Pandas, expressions régulières, OCR (Tesseract)
Difficultés : Enregistrements manuscrits de 250+ ans ; formats de données incohérents ; défis de reconnaissance de caractères ; formats de dates historiques
Mise en place d'un cahier des charges pour la lecture automatique de relevés météorologiques mensuels depuis 250+ ans. Implémentation de pipeline OCR prototype et de règles de validation des données.

EDUCATION

- **ENSAI** Rennes, France
Engineering Degree (MSc.) 2018 – 2021
— Spécialité informatique - Big Data - optimisation - économie (micro & macro) - Délégué de classe

COMPÉTENCES TECHNIQUES

LANGUES

- **Programmation:** Python (avancé), Java, JavaScript/TypeScript, R, Bash, Go
- **Infrastructure:** Docker, Kubernetes, Helm, CI/CD (GitLab, GitHub Actions), Terraform
- **Bases de données:** PostgreSQL, DuckDB, MySQL
- **Stockage:** S3
- **Systèmes:** Linux (Ubuntu/Debian), Windows Server
- **Plateformes Cloud:** Google Cloud Platform (GCP), Amazon Web Services (AWS)
- **Ingénierie des données:** Apache Airflow, Pandas, NumPy, Apache Spark, Dask, Polars, pyarrow, Modin, Ray
- **ML/IA:** scikit-learn, TensorFlow, Transformers, HuggingFace, Fine-tuning de LLM, ML-flow
- **Monitoring:** Prometheus, Grafana, Stack ELK, OpenTelemetry, Datadog
- **Outils DevOps:** Ansible, Vault, ArgoCD, GitHub Workflows
- **Français:** Natif
- **Anglais:** Bilingue
- **Espagnol:** Courant

PROJETS PERSONNELS ET INTÉRÊTS

- **HabitatCalc**

Langages : JavaScript, TypeScript, HTML/CSS

Outils/Packages : React, Chart.js, Bootstrap, GitHub Pages

Difficultés : Calculs financiers complexes ; gestion des cas particuliers ; design responsive pour mobile ; validation des entrées utilisateur

Application immobilière : Optimisation entre location et achat d'un bien immobilier avec des paramètres réels. *HabitatCalc.*
- **TrancheMaster**

Langages : JavaScript, TypeScript, HTML/CSS

Outils/Packages : React, D3.js, GitHub Pages

Difficultés : Calculs complexes de tranches d'imposition ; gestion des taux progressifs ; défis de visualisation ; cas particuliers de la loi fiscale

Application fiscale : Compréhension des tranches marginales d'imposition sur le revenu et le taux d'imposition. *TrancheMaster.*
- **Veille et séminaires:** *L'Etat dans le nuage 2026*, Webinaires INSEE et Services Statistique Publique 2024 à 2026, Salon de l'IA 2023, KubeCon 2023, DevFest 2022 & 2023, VivaTech 2022
- **Sport:** Triathlon, volley-ball, ski alpin, escalade de blocs
- **Musique:** piano (4 ans), batterie (10 ans)